

Lab 1 - Dự đoán giá nhà với hồi quy tuyến tính

1 Giới thiệu bài toán

Mục tiêu của Lab 1 là xây dựng các mô hình hồi quy tuyến tính để dự đoán giá bán nhà dựa trên bộ dữ liệu Ames Housing.

Bộ dữ liệu mô tả nhiều đặc trưng của nhà ở như:

- Thông tin cơ bản: `MSSubClass`, `MSZoning`, `Neighborhood`, `HouseStyle`.
- Diện tích và kích thước: `LotArea`, `LotFrontage`, `GrLivArea`, `TotalBsmtSF`, `GarageArea`.
- Chất lượng và tình trạng: `OverallQual`, `OverallCond`, `KitchenQual`, `ExterQual`.
- Thời gian xây dựng và cải tạo: `YearBuilt`, `YearRemodAdd`, `GarageYrBlt`, `YrSold`.

Biến mục tiêu cần dự đoán là:

- `SalePrice`: giá bán của căn nhà.

2 Dữ liệu cung cấp

Thư mục dữ liệu bao gồm các file sau:

- `train.csv`: tập dữ liệu dùng để huấn luyện mô hình, có chứa cột `SalePrice`.
- `test.csv`: tập dữ liệu dùng để đánh giá mô hình. **Không sử dụng dữ liệu ở tập này trong quá trình huấn luyện**
- `data_description.txt`: mô tả ý nghĩa của các thuộc tính.
- `MSSV.ipynb`: notebook để trình bày bài làm.

Sinh viên cần đọc và xử lý được toàn bộ dữ liệu từ các file trên.

3 Yêu cầu bài làm

3.1 Yêu cầu 1: Phân tích khám phá dữ liệu (1 điểm)

Thực hiện phân tích khám phá dữ liệu chủ yếu trên tập huấn luyện `train.csv`.

Các nội dung gợi ý bao gồm:

- In ra số dòng, số cột, tên cột, kiểu dữ liệu.
- Kiểm tra số lượng giá trị thiếu theo từng cột.
- **Thống kê mô tả cho các đặc trưng số.**
- Phân tích phân phối của biến mục tiêu `SalePrice`.
- Vẽ các biểu đồ như histogram, boxplot, scatter plot, heatmap để hiểu rõ dữ liệu.

Có thể đối chiếu một số thống kê cơ bản giữa tập huấn luyện và tập kiểm tra, nhưng không dùng tập kiểm tra để điều chỉnh mô hình.

3.2 Yêu cầu 2: Xây dựng mô hình hồi quy tuyến tính (9 điểm)

Trong toàn bộ phần này, sinh viên chỉ sử dụng các mô hình thuộc họ hồi quy tuyến tính. **Độ đo chính để đánh giá là MAE.**

Yêu cầu 2a: Sử dụng **toàn bộ đặc trưng đầu vào (3 điểm)**

- Huấn luyện một mô hình hồi quy tuyến tính sử dụng toàn bộ đặc trưng đầu vào sau khi tiền xử lý phù hợp.
- **Trình bày công thức hồi quy của mô hình**, trong đó các hệ số được làm tròn đến 3 chữ số thập phân.
- **Báo cáo MAE của mô hình trên tập kiểm tra `test.csv`.**

Yêu cầu 2b: Sử dụng duy nhất một đặc trưng (3 điểm)

- Chọn ra 5 đặc trưng tốt nhất từ câu 1 hoặc sinh viên có thể tự suy diễn ra.
- Xây dựng một mô hình cho **từng** đặc trưng đầu vào riêng lẻ.
- Dùng k-fold cross-validation trên tập huấn luyện để chọn ra đặc trưng tốt nhất.
- Chỉ xáo trộn dữ liệu một lần và giữ cùng một thiết lập chia cho mọi đặc trưng ứng viên.
- Sau khi chọn được đặc trưng tốt nhất, huấn luyện lại mô hình trên toàn bộ tập huấn luyện.
- Báo cáo:
 - MAE trung bình từ cross-validation cho từng đặc trưng.
 - MAE trên tập kiểm tra `test.csv` của mô hình tốt nhất.
 - **Công thức hồi quy của mô hình tốt nhất.**

Yêu cầu 2c: Tự thiết kế các mô hình đặc trưng (3 điểm)

- Thiết kế **ít nhất 3 phương án** đặc trưng hoặc biến đổi đặc trưng **khác nhau**.
- Có thể sử dụng một số ý tưởng như:
 - Chọn tập con đặc trưng.
 - Kết hợp nhiều đặc trưng số.
 - Biến đổi đặc trưng như bình phương, log hoặc chuẩn hóa.
 - **Tạo đặc trưng mới từ các cột sẵn có.**
- Dùng k-fold cross-validation **trên tập huấn luyện** để chọn ra phương án tốt nhất.
- Không dùng tập kiểm tra để chọn mô hình.
- Sau khi chọn được mô hình tốt nhất, huấn luyện lại trên toàn bộ tập huấn luyện và báo cáo MAE trên tập kiểm tra `test.csv`.
- Trình bày **công thức hồi quy của mô hình tốt nhất** tìm được.

4 Yêu cầu nộp bài

- Bài làm được trình bày trong file `MSSV.ipynb`. (Lưu ý: thay tên file MSSV thành MSSV của sinh viên)
- Báo cáo tương ứng trong file `MSSV.pdf`: Cần đưa ra được các phân tích/ lý do chọn các mô hình và nhận xét trên kết quả tương ứng của bài làm.
- Cần ghi rõ thông tin sinh viên: họ và tên, MSSV, lớp.

- Notebook phải chạy được từ đầu đến cuối mà không phát sinh lỗi.
- Nếu có sinh thêm file kết quả hoặc file dự đoán, cần mô tả rõ cách tạo trong notebook hoặc mã nguồn đi kèm.

5 Lưu ý

- Ở lab này sinh viên **chỉ được** sử dụng mô hình hồi quy tuyến tính (Linear Regression) để thực hiện bài làm.
- Sinh viên không được tự ý đổi template của file notebook. Có thể thêm các code/markdown block nhưng các block có sẵn thì giữ nguyên.
- Có thể sử dụng các thư viện phổ biến như NumPy, pandas, matplotlib. Tuy nhiên các thư viện hỗ trợ trực tiếp việc training, khởi tạo mô hình bị cấm sử dụng (Ví dụ như scikit-learn,...)
- Cần giải thích ngắn gọn cách tiền xử lý dữ liệu, cách chọn mô hình và ý nghĩa của kết quả MAE.
- Khuyến khích trình bày thêm nhận xét về ưu điểm và hạn chế của từng cách xây dựng mô hình.
- Dataset được cung cấp đã có chỉnh sửa nên sinh viên không nên download các dataset từ các nguồn khác.
- Sinh viên có thể sử dụng AI để hỗ trợ trong việc giải thích các khái niệm tuy nhiên nghiêm cấm các hành vi sử dụng AI để hoàn thành đề án (cả trong file template lẫn báo cáo). Trong trường hợp bài làm được cho là AI làm, đề án này sẽ được chấm 0 điểm.