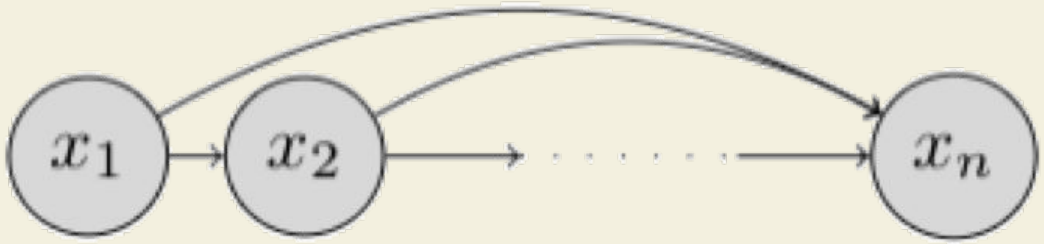
MTH00056: Phương pháp toán cho AI
Mô hình ngôn ngữ

Trình bày: Cấn Trần Thành Trung[1,2]



$$p(x_1,x_2,\ldots,x_n)= p(x_1)p(x_2|x_1)\ldots p(x_n|x_1,x_2,\ldots,x_{n-1})$$

1. Khoa Công nghệ thông tin, Trường ĐH Khoa học tự nhiên, ĐHQG-HCM
2. PiMA Academy, Việt Nam

Các nội dung hôm nay

1. Mô hình ngôn ngữ
2. Mô hình *n-gram*
3. Mạng nơ-ron transformer

Tài liệu tham khảo

[1] Jurafsky & Martin's course: Link
[2] Xiao & Zhu’s book: Link
[3] Lena Voita's blog: Link
[4] Stanford’s building LLMs lecture: Link

Các nội dung hôm nay

1. **Mô hình ngôn ngữ**
2. Mô hình *n-gram*
3. Mạng nơ-ron Transformer

Mô hình ngôn ngữ lớn (Large language models - LLMs)

- Mô hình (tạo sinh ngôn ngữ)
- Thuật toán
- Dữ liệu
- Đánh giá
- Hệ thống (phần cứng như GPUs)



Mô hình ngôn ngữ lớn

Tiền huấn luyện (pre-training): GPT3 (Generative Pre-trained Transformer 3)

- Mô hình tạo sinh ngôn ngữ tự nhiên
- Lượng lớn ‘kiến thức’ từ kho ngữ liệu khổng lồ (corpus)

Hậu huấn luyện (post-training): ChatGPT, Gemini, Claude, v.v.

- Thực hiện thêm được các tác vụ như trả lời câu hỏi, lập trình, giải toán, v.v.
- Học thêm được ‘tri thức’

Mô hình ngôn ngữ

Định nghĩa. Một mô hình ngôn ngữ L là một phân bố xác suất trên tập hợp các dãy hữu hạn từ/token:

$$X_1,X_2,\ldots,X_n \sim P(x_1,x_2,\ldots,x_n)$$

Mỗi từ/token thuộc tập từ vựng V cho trước.

Lưu ý: n có thể thay đổi

Ví dụ 1. *Viết bảng*

Mô hình ngôn ngữ tạo sinh

Nhắc lại:

- Một phân bố xác suất cho ta biết khả năng kết quả (bnn) nhận các giá trị cụ thể.

- Nếu bnn $(X_1,X_2,...,X_n) \sim P(x_1,x_2,...,x_n)$, ta có thể ***lấy mẫu*** từ P để nhận được một giá trị cụ thể của $(X_1,X_2,...,X_n)$.

=> Mô hình ngôn ngữ L là mô hình tạo sinh.

Ví dụ 2. *Viết bảng*

Mô hình ngôn ngữ tự hồi quy (Autoregressive language models)

Quy tắc chuỗi (chain-rule) cho xác suất:

$$p(x_1,x_2,\ldots,x_n) = p(x_1)p(x_2|x_1)\ldots p(x_n|x_1,x_2,\ldots,x_{n-1})$$

C/M. Viết bảng

=> Chỉ cần dự đoán được từ/token tiếp theo khi biết ngữ cảnh (tại sao?)

Vì sao dự đoán từ tiếp theo là thông minh?

- "the science of making machines do things that would require intelligence if done by men” - Marvin Minsky



Token

- Token tổng quát hơn từ (một phần của từ)
- Tại sao cần token?
  - Lỗi chính tả: toai, thichs
  - Một số ngôn ngữ không có khoảng trống giữa từ (tiếng Thái)
- Token hóa chuyển đổi đầu vào (prompt) thành chuỗi token
- Phi token hóa chuyển token thành từ
- Tổng số token phân biệt là kích thước của V
- Cần thuật toán để tạo ra tập token V và token hóa (chẳng hạn bye pair encoding)



Mô hình ngôn ngữ tự hồi quy (Autoregressive language models)

- Tác vụ: Dự đoán token tiếp theo
  ⇔ Tính phân bố xác suất cho token tiếp theo

- Các bước thực hiện

1. Token hóa
2. Input cho mô hình L
3. Output: Phân bố xác suất cho token tiếp theo
4. Lấy mẫu
5. Phi token hóa

Viết bảng sơ đồ minh họa

Mô hình và thuật toán huấn luyện

- Tập ngữ liệu (corpus) D
- Mô hình cho L: mô hình n-gram/mạng nơ-ron transformer
- Mô hình n-gram: Thuật toán đếm tần suất & làm mượt Laplace
- Mạng transformer: Thuật toán gradient descent cho hàm mất mát

Đánh giá mô hình ngôn ngữ tạo sinh

- Sử dụng độ phân vân (perplexity) của mô hình với văn bản thẩm định

- Độ phân vân (perplexity) của mô hình L với một văn bản có N token

$$W = (w_1, w_2 \ldots, w_N)$$

được tính bởi

$$PP(W) = P(W)^{-1/N},$$

trong đó P(W) là độ hợp lý của văn bản W:

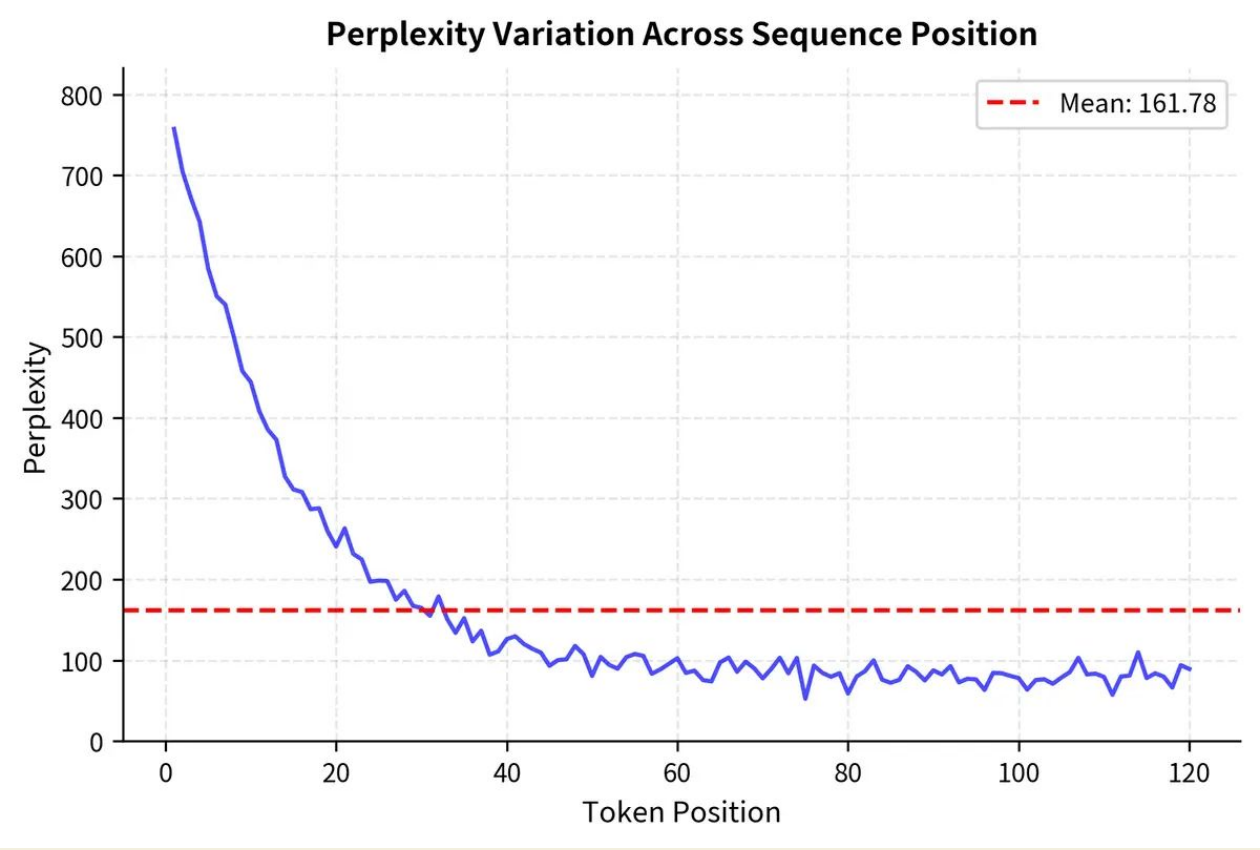
$$P(W) = p(w_1)\, p(w_2|w_1) \ldots p(w_n|w_1, \ldots, w_{n-1})$$

- Câu hỏi: GTNN/GTLN của độ phân vân bằng bao nhiêu?

Đánh giá L bằng độ phân vân (perplexity)

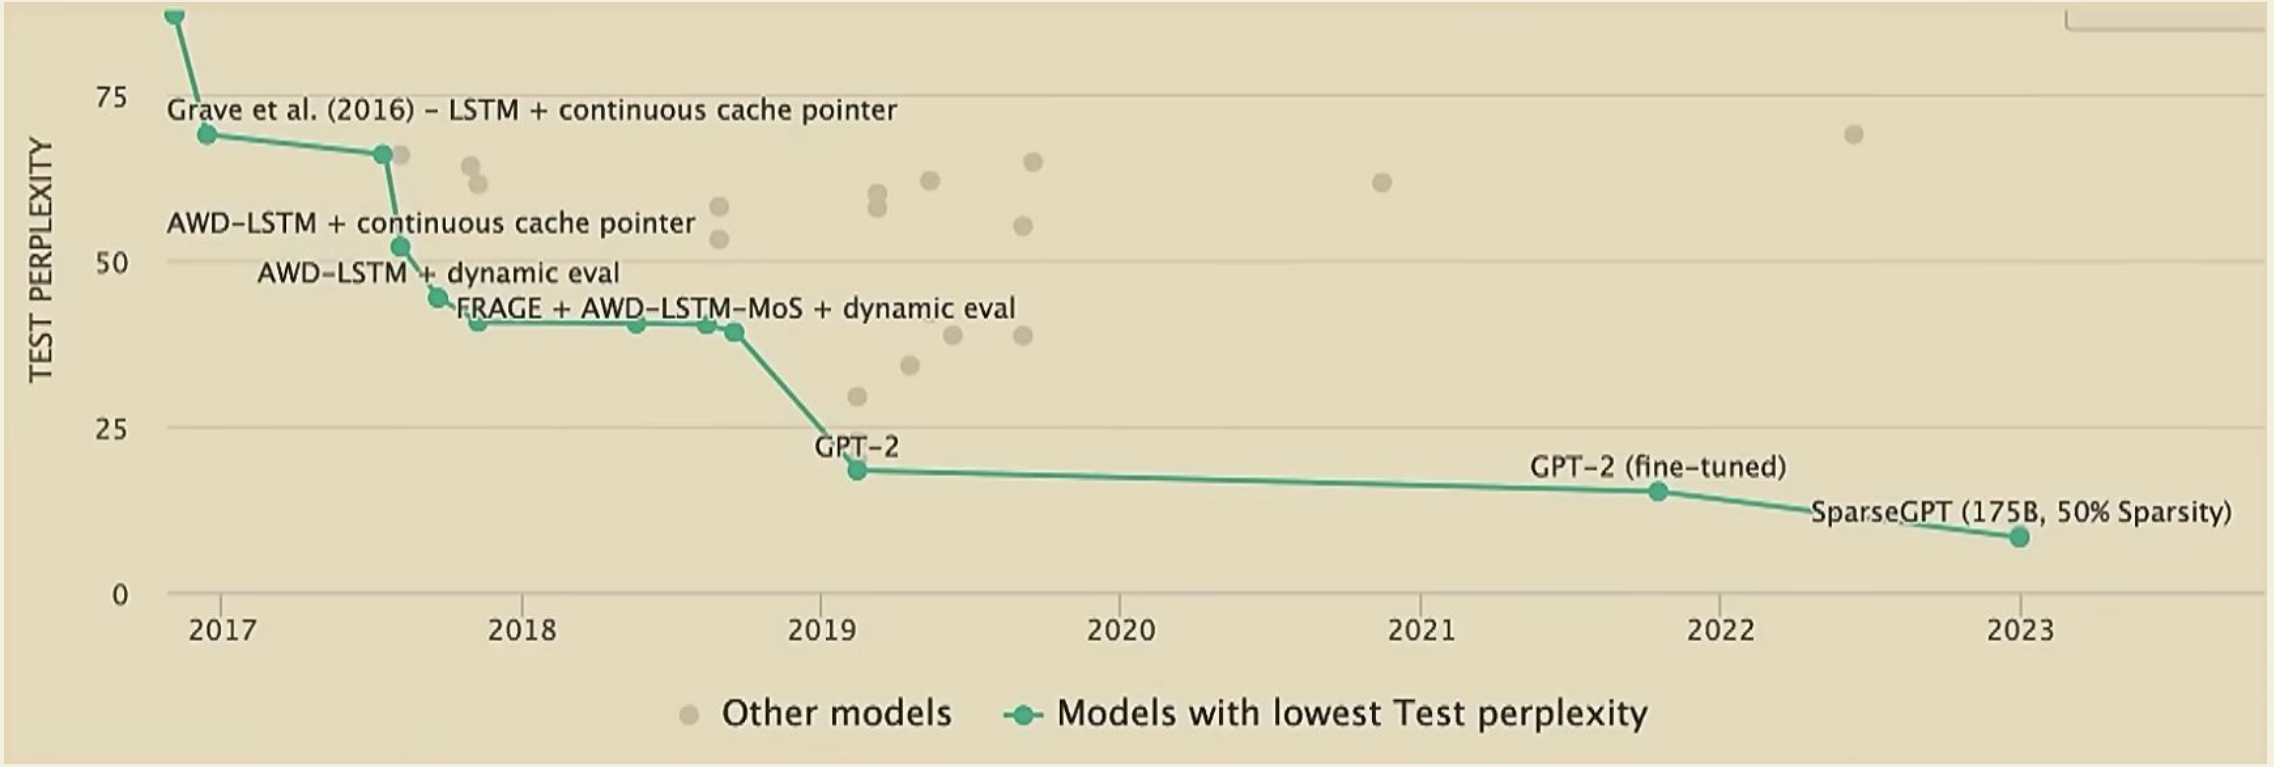
- 1 <= độ phân vân <= |V|
- Tác vụ: Dự đoán token tiếp theo
- Ý nghĩa: Độ phân vân là số lượng token trung bình mô hình “cân nhắc" lựa chọn

Đánh giá L bằng độ phân vân (perplexity)



Nguồn: https://huggingface.co/learn/llm-course/en/chapter6/5

Đánh giá L bằng độ phân vân (perplexity)



Nguồn: [Stanford's building LLMs lecture]

Các nội dung hôm nay

1. Mô hình ngôn ngữ
2. **Mô hình *n-gram***
3. Mạng nơ-ron transformer

Mô hình n-gram

- Mô hình bigram (2-gram) thêm giả thiết Markov

$$p(x_i|x_1,x_2,...,x_{i-1})=p(x_i|x_{i-1})$$

=> chỉ còn phải tính $p(x_{i-1})$ và $p(x_{i-1},x_i)$

- Mô hình trigram (3-gram) thêm giả thiết

$$p(x_i|x_1,x_2,...,x_{i-1})=p(x_i|x_{i-2},x_{i-1})$$

=> chỉ còn phải tính $p(x_{i-1})$, $p(x_{i-1},x_i)$ và $p(x_{i-2},x_{i-1},x_i)$

Đếm tần suất

- Ước lượng $p(x_i|x_1,x_2,...,x_{i-1})$ bằng cách đếm tần suất xuất hiện của $(x_1,x_2,...,x_{i-1},x_i)$ và $(x_1,x_2,...,x_{i-1})$ trong corpus:

$$p(x_i|x_1,x_2,...,x_{i-1}) = C(x_1,x_2,...,x_{i-1},x_i)/C(x_1,x_2,...,x_{i-1}),$$

trong đó $C(x_1,x_2,...,x_j)$ là số lần xuất hiện trong corpus của chuỗi $(x_1,x_2,...,x_j)$.

- Đếm tần suất tương đương với MLE
- Vấn đề: Chuỗi không có trong corpus sẽ không được tạo sinh ra do có xác suất = 0

Làm mịn Laplace

- Ước lượng $p(x_i|x_1,x_2,...,x_{i-1})$ bằng cách đếm tần suất xuất hiện trong corpus và làm mịn

$$p(x_i|x_1,x_2,...,x_{i-1}) = [C(x_1,x_2,...,x_{i-1},x_i)+1]/[C(x_1,x_2,...,x_{i-1})+|V|].$$

- Mỗi chuỗi chưa có trong corpus có xác suất được sinh ra bé hơn hoặc bằng $1/|V|$.

Ví dụ: Bài 5 (Ôn thi cuối kỳ)

- Cho V = {học, vui, chơi, <end>}
  Corpus gồm 3 câu như sau:
  - học chơi vui <end>
  - chơi vui <end>
  - học vui <end>
- Tính phân bố xác suất của mô hình trigram

Viết bảng

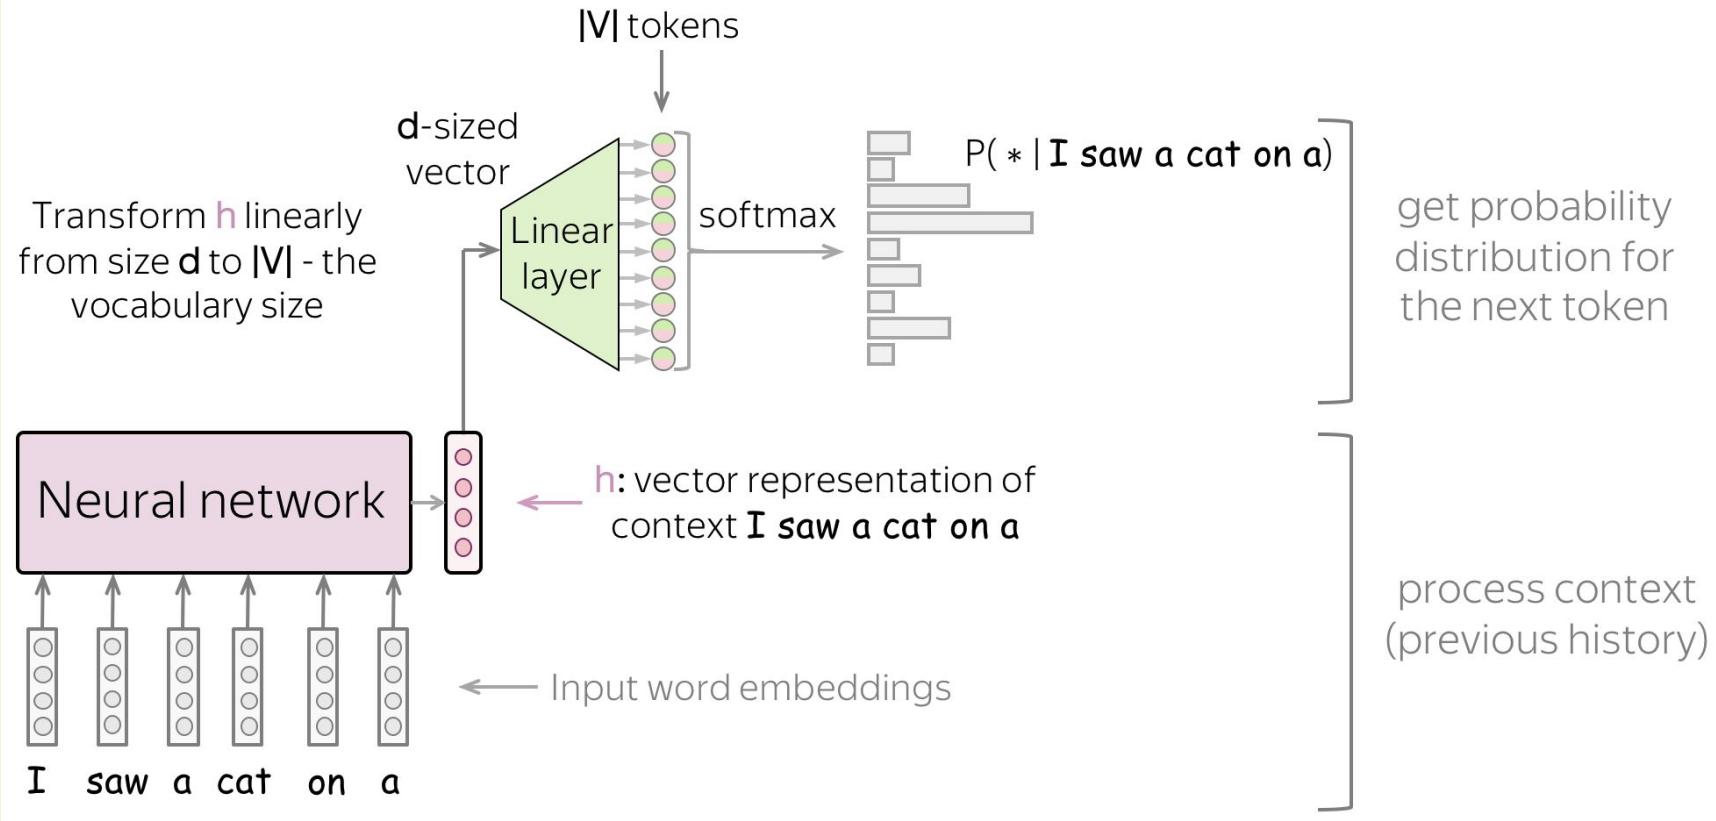
Các nội dung hôm nay

1. Mô hình ngôn ngữ
2. Mô hình *n-gram*
3. **Mạng nơ-ron transformer**

Mạng nơ-ron ngôn ngữ

- Mạng nơ-ron và phân bố xác suất đều là hàm số

=> dùng mạng nơ-ron ước lượng L

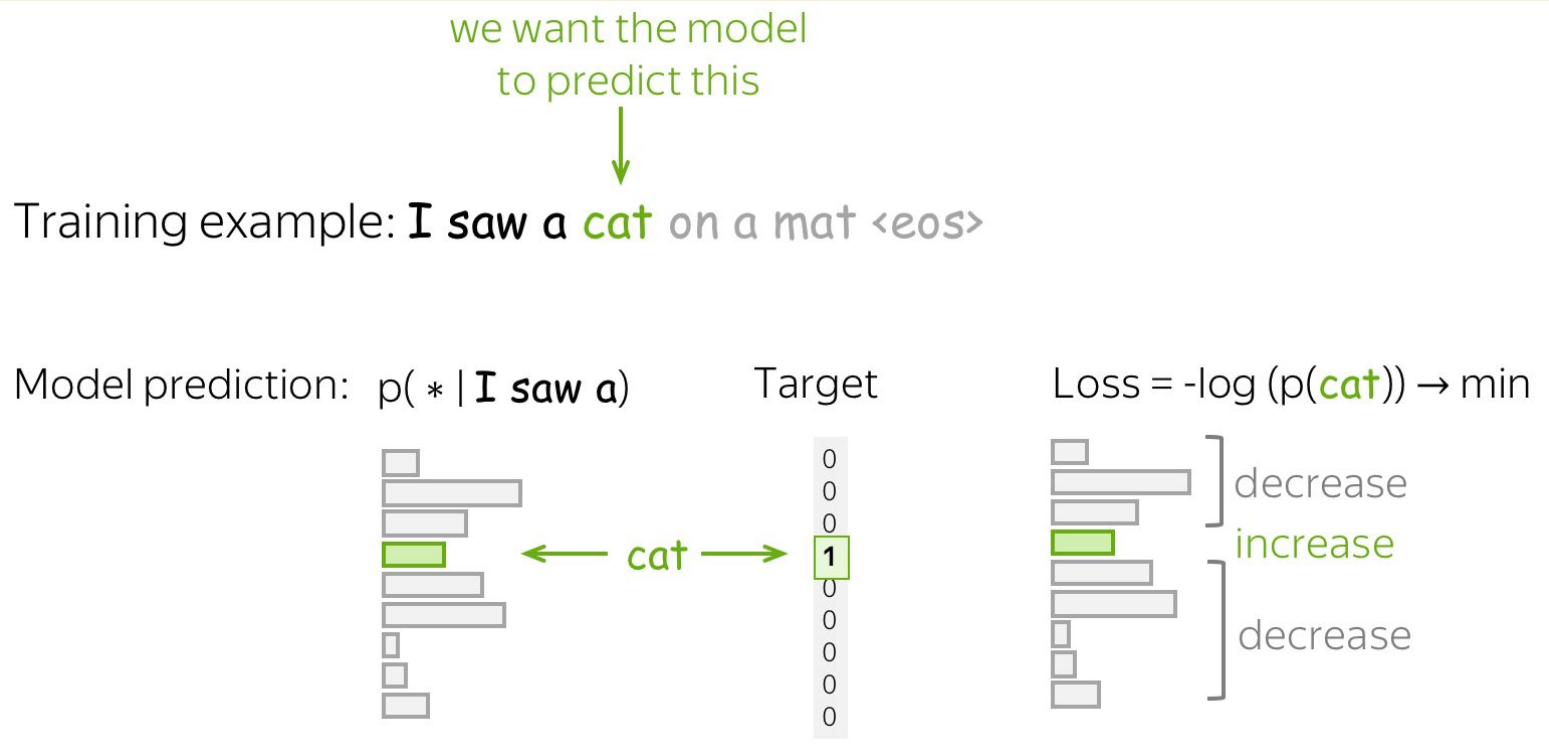


Nguồn: Lena Voita's blog (Link)

Hàm mất mát entropy chéo (cross-entropy)

- Hàm entropy chéo để so sánh hai phân bố xác suất
  1. Dự đoán của mô hình: $p^* = p(*|x_1, \ldots, x_{j-1})$ trên V
  2. Phân bố one-hot p trên V ở x_j (theo mẫu dữ liệu huấn luyện)

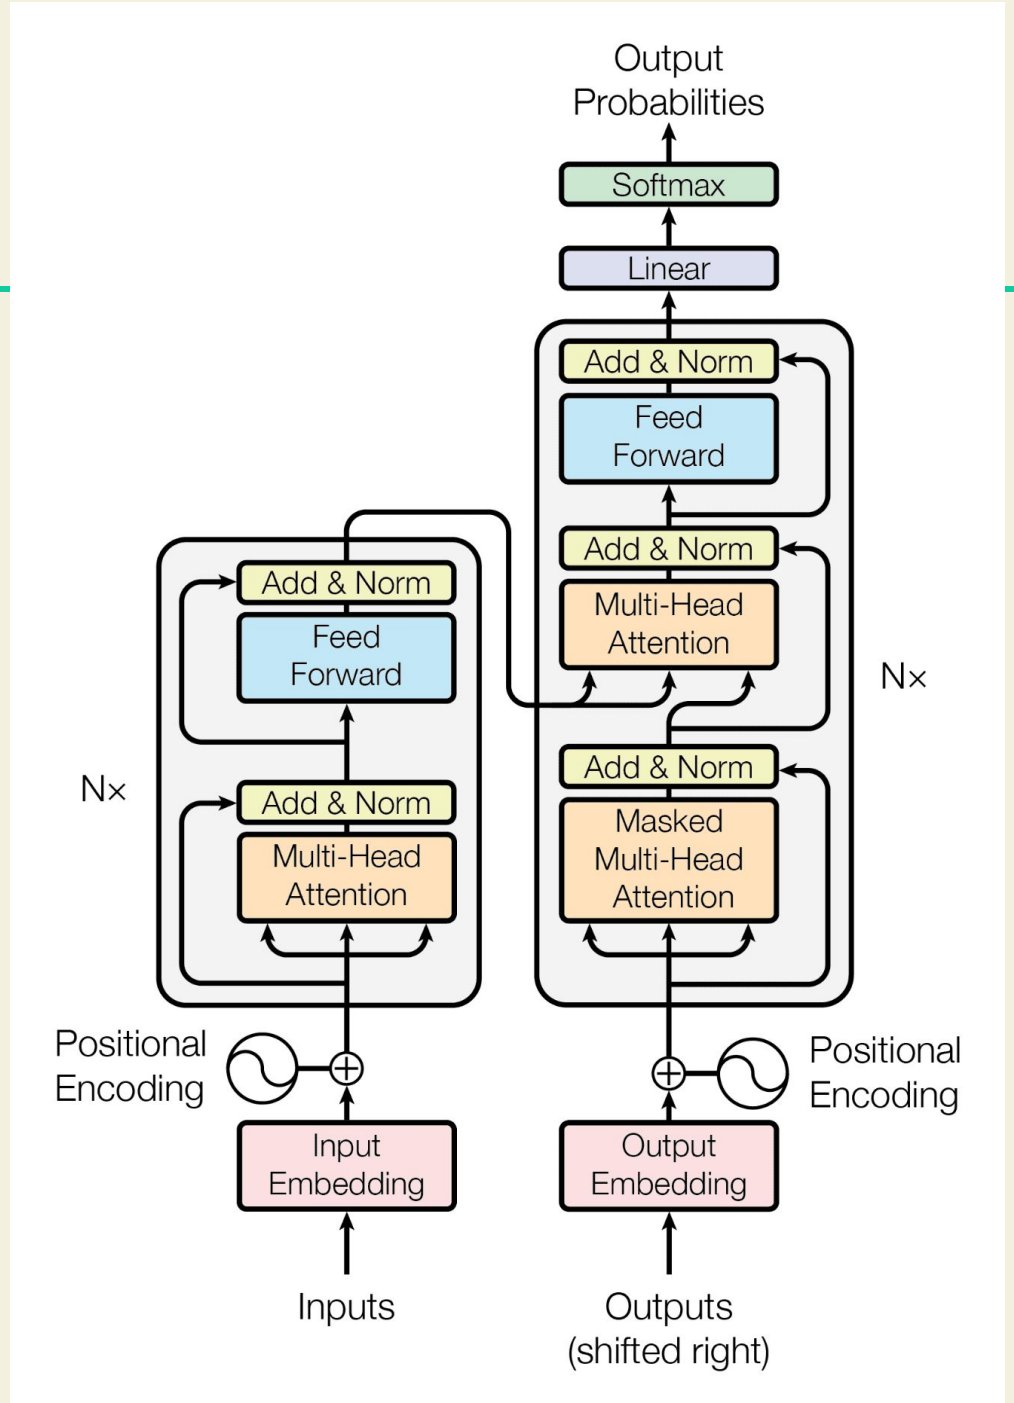
Viết công thức lên bảng



Nguồn: Lena Voita's blog (Link)

Transformer

Source: [Attention Is All You Need]



Đúc kết

- Mô hình ngôn ngữ L là một phân bố xác suất trên các dãy từ
- Để sinh ra ngôn ngữ: Ta tính phân bố xác suất trên V của token tiếp theo rồi lấy mẫu
- Mô hình SOTA để ước lượng phân bố xác suất L là mạng nơ-ron transformer

Hỏi & Đáp (Q&A)

Cảm ơn các bạn đã lắng nghe!

 ctttrung@fit.hcmus.edu.vn