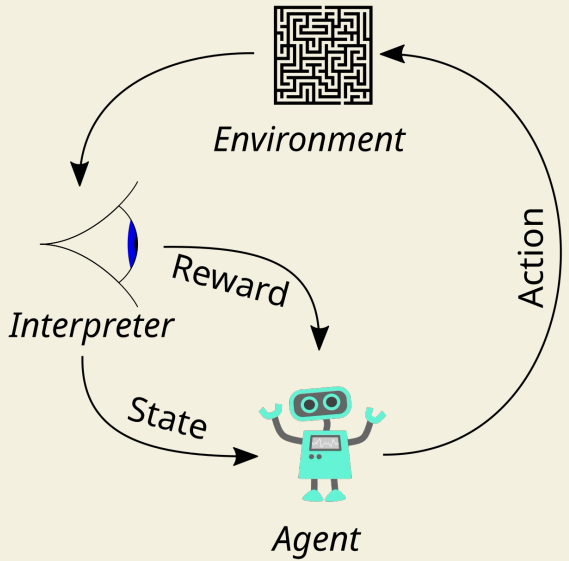
MTH56: Phương pháp toán cho AI
Giới thiệu về học tăng cường

Trình bày: Cấn Trần Thành Trung[1,2]



1. Khoa Công nghệ thông tin, Trường ĐH Khoa học tự nhiên, ĐHQG-HCM
2. PiMA Academy, Việt Nam

Các nội dung hôm nay

1. Tổng quan
2. Quá trình quyết định Markov
3. Học khi biết về môi trường
4. Học khi không biết về môi trường

Tài liệu tham khảo

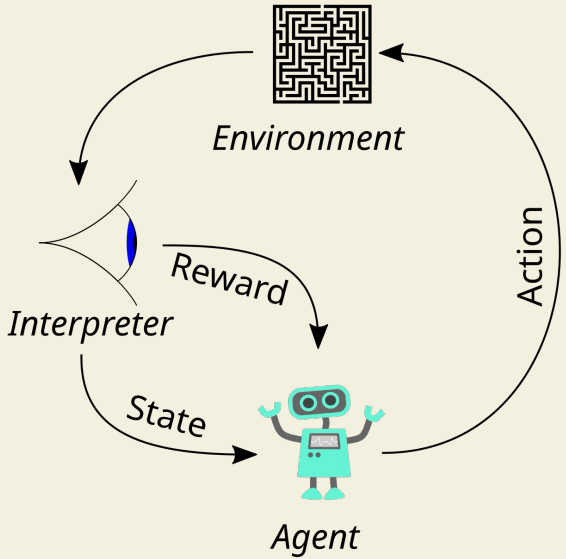
[1] Sutton & Barto’s book: Link
[2] Mannor, Mansour & Tamar’s book: Link
[3] Mini-course của GS. Trần Thanh Long: Link

Các nội dung hôm nay

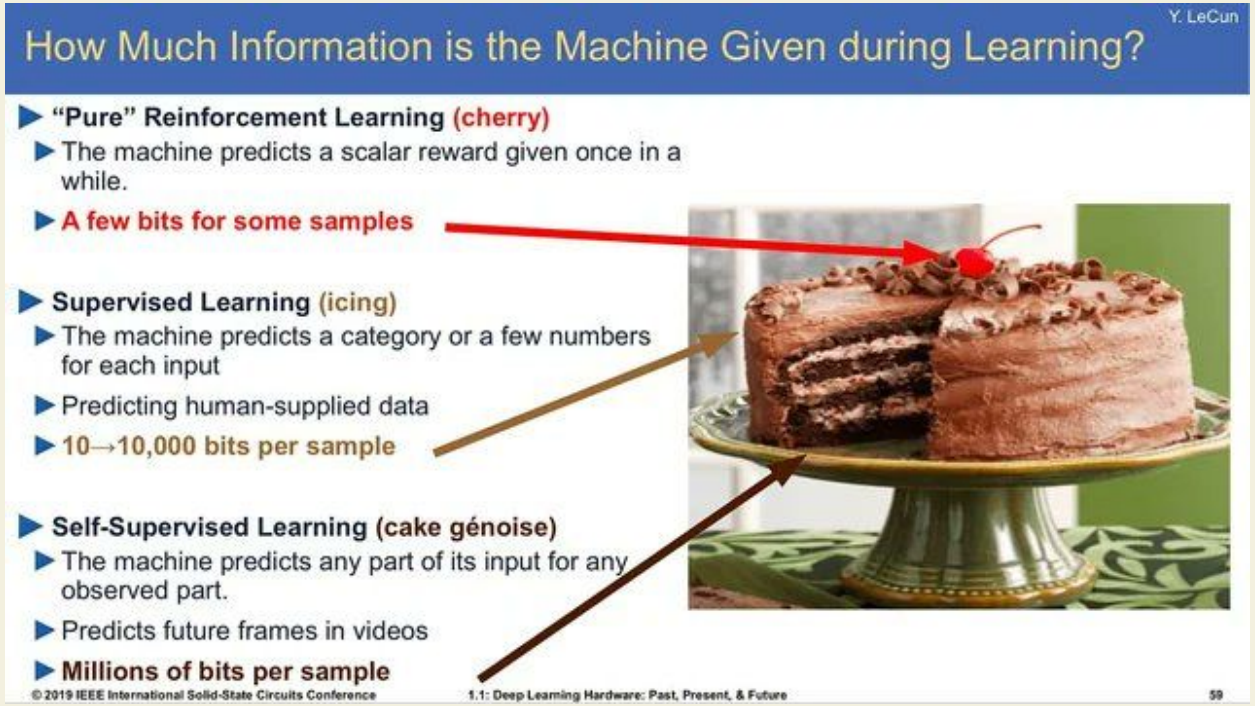
1. **Tổng quan**
2. Quá trình quyết định Markov
3. Học khi biết về môi trường
4. Học khi không biết về môi trường

Định nghĩa vắn tắt

Học tăng cường (Reinforcement learning - RL) nghiên cứu các mô hình và thuật toán để tác nhân (agent) có thể học theo thời gian thông qua việc tương tác với môi trường.



Học tăng cường trong học máy

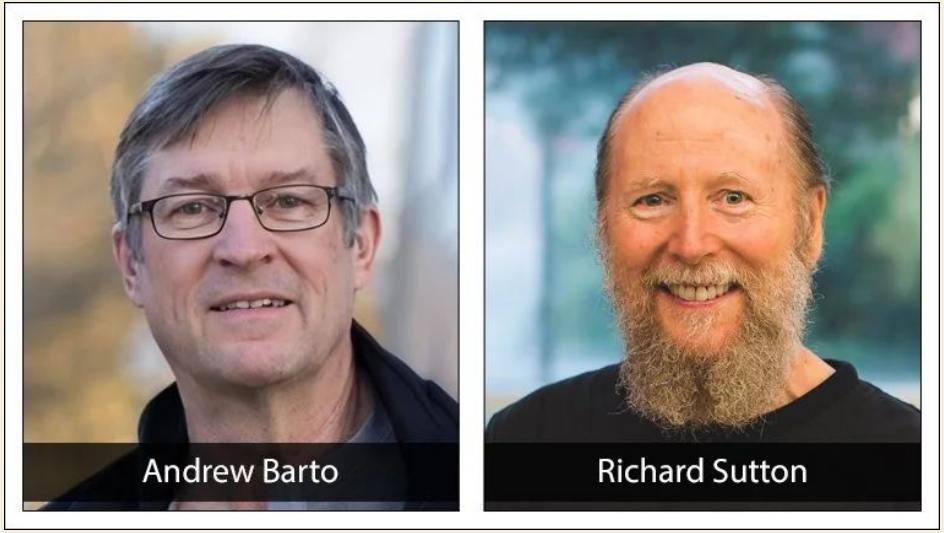




Yann LeCun's talk at ICML 2016

Lược sử học tăng cường (Reinforcement learning - RL)

1950s	1980s	2016	2025
Optimal control Bellman's works	Sutton & Barton's foundational works	AlphaGo	DeepSeek R1



Lược sử học tăng cường (Reinforcement learning - RL)

1950s	1980s	2016	2025
Optimal control Bellman's works	Sutton & Barton's foundational works	AlphaGo	DeepSeek R1



AlphaGo (2016)

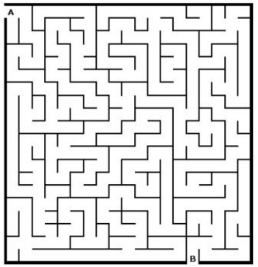
AlphaGo kết hợp học sâu và học tăng cường đánh bại kỳ thủ cờ vây số 1 Thế Giới Lee Sedol

DeepSeek R1 (2025)

Mô hình suy luận sử dụng học tăng cường làm thị trường chứng khoán Mĩ bốc hơi gần 1000 tỉ đô-la.

Ứng dụng của học tăng cường







Source: Dailymail.co.uk



Source: Google Research



https://towardsdatascience.com/reinforcement-learning-towards-general-ai-1bd68256c72d

=> Khi cần giải bài toán đưa ra chuỗi quyết định theo thời gian (sequential decision making-SDM): xem Link

Học tăng cường trong học máy

- **"Pure" Reinforcement Learning (cherry)**
  - The machine predicts a scalar reward given once in a while.
  - **A few bits for some samples**
- **Supervised Learning (icing)**
  - The machine predicts a category or a few numbers for each input
  - Predicting human-supplied data
  - **10→10,000 bits per sample**
- **Unsupervised/Predictive Learning (cake)**
  - The machine predicts any part of its input for any observed part.
  - Predicts future frames in videos
  - **Millions of bits per sample**



- (Yes, I know, this picture is slightly offensive to RL folks. But I'll make it up)

Đọc thêm ở link sau

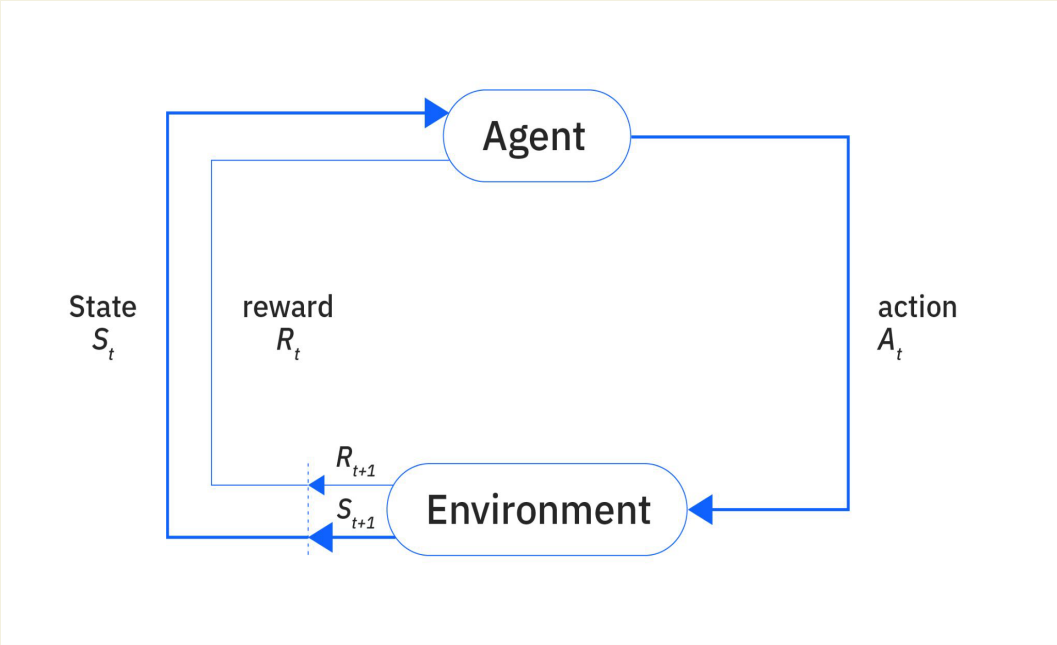
Các nội dung hôm nay

1. Tổng quan
2. **Quá trình quyết định Markov**
3. Học khi biết về môi trường
4. Học khi không biết về môi trường

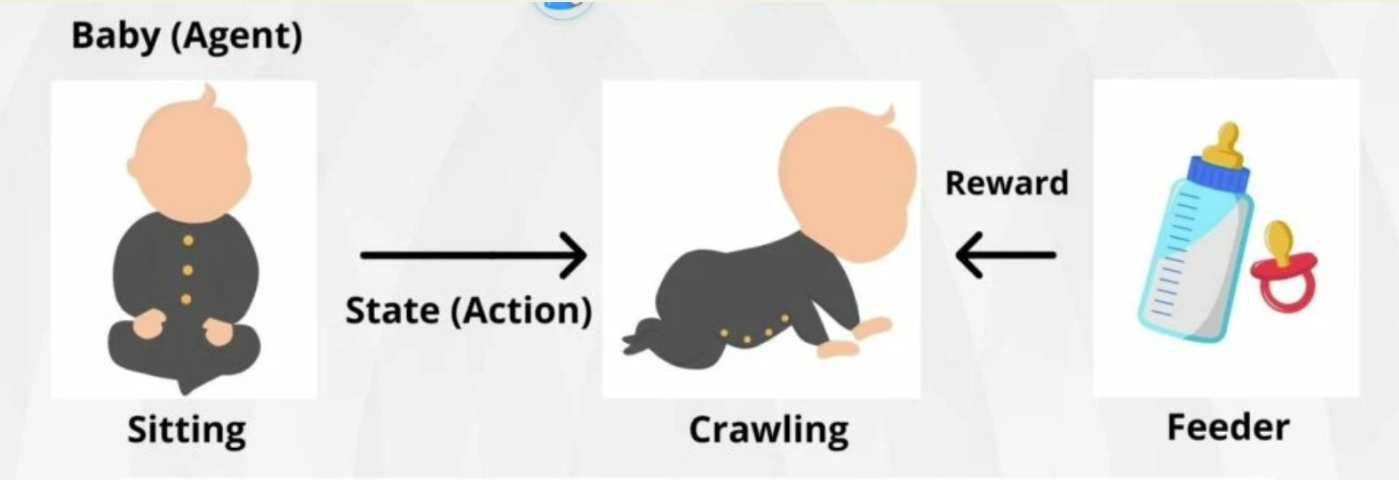
Quá trình quyết định Markov
Markov decision process (MDP)

Bao gồm các thành phần sau:

- Mốc thời gian T= {0, 1, 2, …}
- Trạng thái S: tập hợp tất cả trạng thái có thể của môi trường
- Hành động A: tập hợp tất cả hành động tác nhân có thể làm
- Phần thưởng R: giá trị nhận được ngay sau mỗi hành động trong một trạng thái
- Hàm xác suất P: cho biết khả năng xảy ra trạng thái tiếp theo sau mỗi hành động

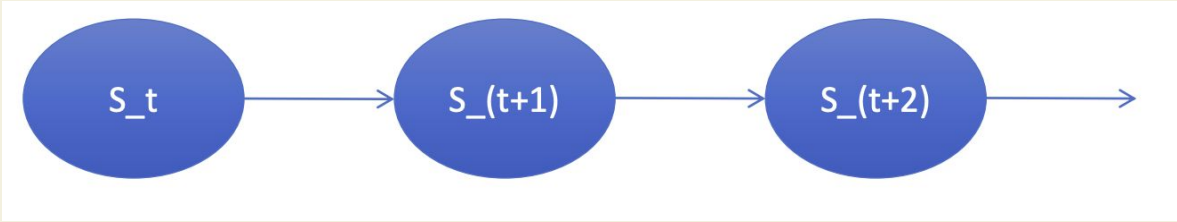


Ví dụ: Em bé ‘học’ từ tương tác với môi trường





Quá trình Markov

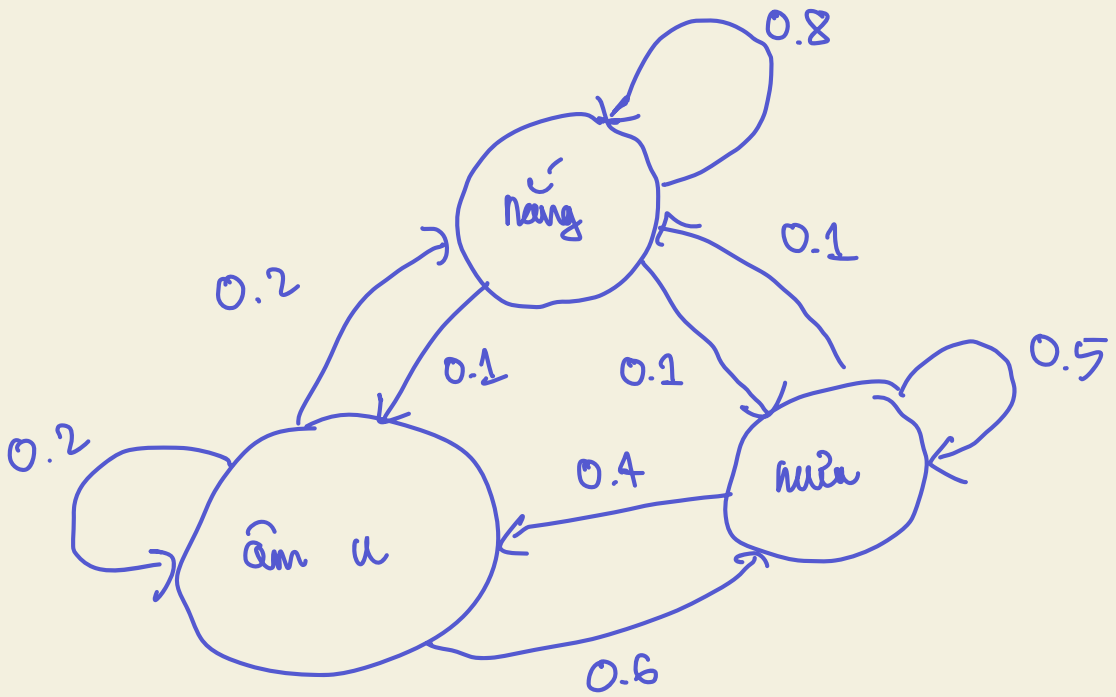


Định nghĩa. Là quá trình các trạng thái thay đổi ngẫu nhiên theo thời gian $S_1,S_2,...,S_t,...$ thỏa mãn tính chất Markov:

$$P(S_{t+1}= s \mid S_t,S_{t-1},...,S_1) = P(S_{t+1}= s \mid S_t).$$

- Trạng thái S_t là biến ngẫu nhiên nhận giá trị trong S.
- Tập hợp $H_t= \{S_1,S_2,...,S_{t-1}\}$ được gọi là lịch sử tại thời điểm t.
- Xác suất $P(S_{t+1}= s' \mid S_t = s)$ được gọi là xác suất chuyển trạng thái.
  Khi S hữu hạn, ma trận vuông kích thước |S|x|S| chứa xác suất chuyển trạng thái gọi là ma trận chuyển trạng thái.

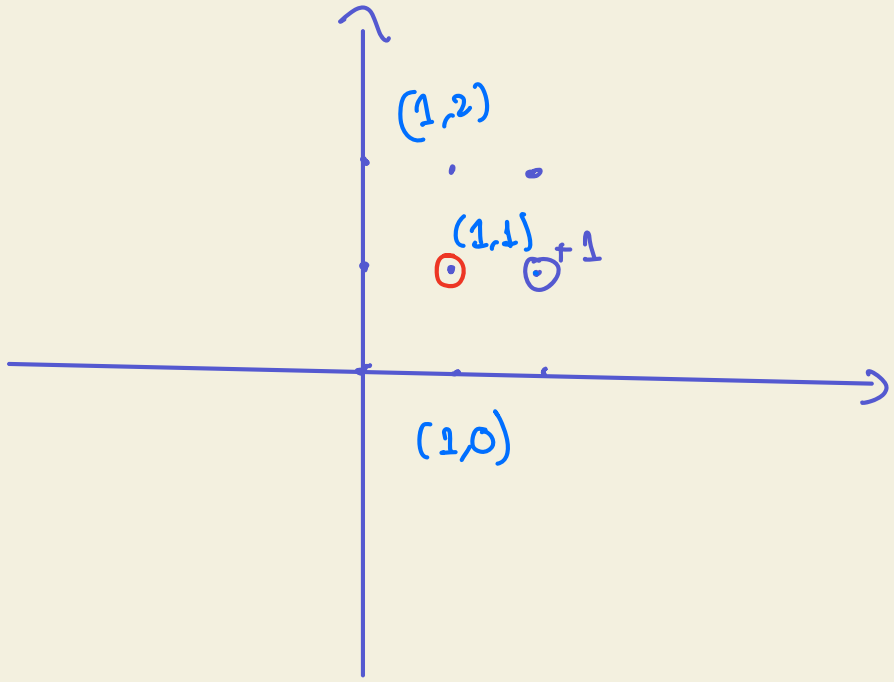
Ví dụ: Trời nắng, âm u, hoặc mưa



P_S

	nắng	mưa	âm u
nắng	0.8	0.1	0.2
mưa	0.1	0.5	0.6
âm u	0.1	0.4	0.2

Ví dụ: Người say rượu đi trên lưới điểm nguyên

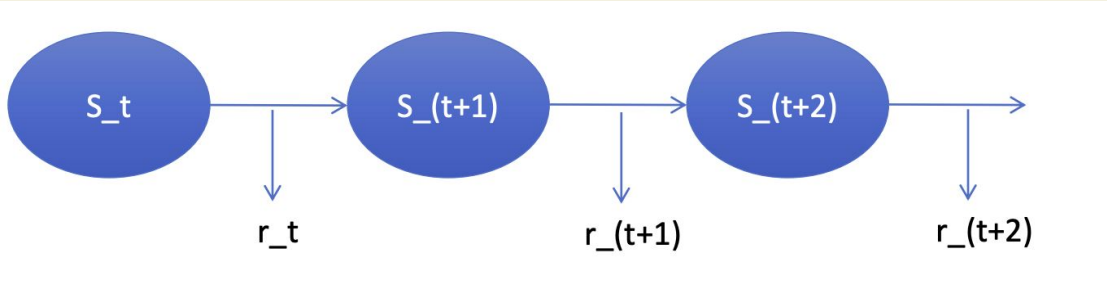


$$S = \{(x, y) : x \in \mathbb{Z}, y \in \mathbb{Z}\}$$

$$P(S_{t+1} = (x', y') \mid S_t = (x, y))$$

$$= \begin{cases} \frac{1}{4} & \text{nếu } |x' - x| + |y' - y| = 1 \\ 0 & \end{cases}$$

Quá trình Markov có thưởng
Markov reward process (MRP)



Định nghĩa.

- Hàm phần thưởng (tức thời) R: SxS -> {số thực}. Phần thưởng R_t là biến ngẫu nhiên và bằng R(s',s) nếu S_{t+1}=s', S_t=s. Hàm phần thưởng ở trạng thái s:

$$R(s) = E(R_t \mid S_t=s) = \sum P(S_{t+1}=s' \mid S_t=s)\, R(s',s).$$

- Chọn 0 < c < 1 là hằng số mất giá. Hàm phần thưởng tổng:

$$G_t = R_t + cR_{t+1} + c^2R_{t+2} + \dots$$

$S = \{s_1, \dots, s_n\}$

- Giá trị của trạng thái s là:

$$V(s) = E(G_t \mid S_t=s).$$

$$V(S) = \begin{pmatrix} V(s_1) \\ \vdots \end{pmatrix}$$

Phương trình Bellman cơ bản

$V(s) = R(s) + c \, P_s \, V(s)$

- Giá trị của trạng thái s là:

$$V(s) = E(G_t \mid S_t=s) = E(R_t + cR_{t+1} + c^2R_{t+2} + \dots \mid S_t=s)$$

$$= E(R_t \mid S_t=s) + c\,E(R_{t+1} + cR_{t+2} + c^2R_{t+3} + \dots \mid S_t=s)$$

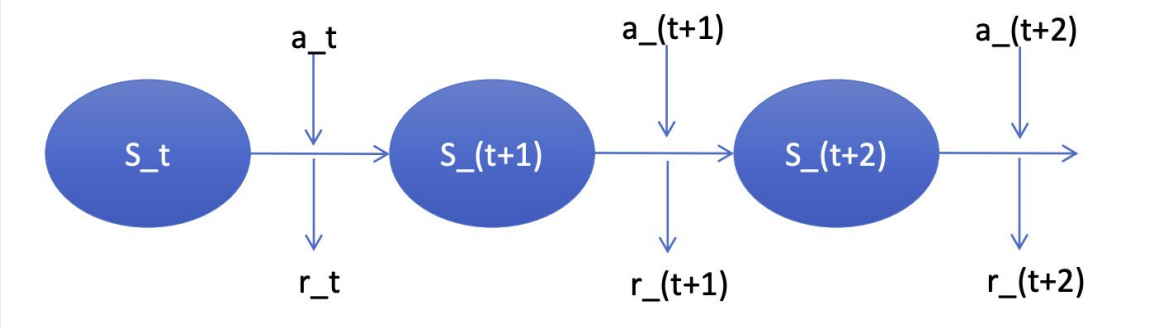
$$= R(s) + c \sum_{s' \in S} P(S_{t+1}=s' \mid S_t=s)\, E(R_{t+1} + \dots \mid S_{t+2}=s', S_t=s)$$

$$= R(s) + c \sum_{s' \in S} P(s' \mid s) V(s')$$

$E(\ \dots\ \mid S_{t+1}=s') = V(s')$

Ví dụ: Người say rượu đi trên lưới điểm nguyên

Quá trình Markov có hành động & thưởng (MDP)



Định nghĩa.

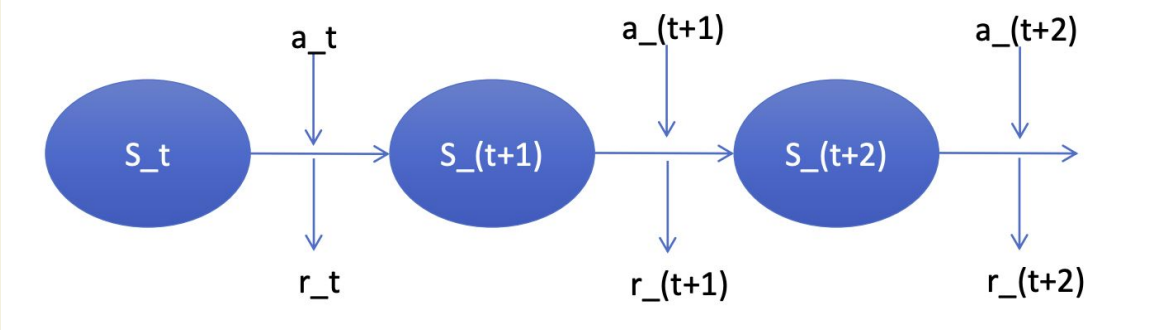
- Tập A là tập tất cả hành động. Ở thời gian t, hành động A_t là biến ngẫu nhiên nhận giá trị trong A.

- Hàm xác suất chuyển trạng thái ứng với hành động:

$$P(S_{t+1}= s' \mid S_t=s, A_t=a).$$

- Hàm phần thưởng (tức thời) R: SxA -> {số thực}. Phần thưởng R_t là biến ngẫu nhiên và bằng R(s,a) nếu $S_t=s$, $A_t=a$.

Quá trình Markov có hành động & thưởng (MDP)



Định nghĩa.

- Hàm phần thưởng là

$$R(s) = E(R_t \mid S_t = s).$$

- Với hằng số mất giá 0<= c <=0. Hàm phần thưởng tổng là

$$G_t = R_t + cR_{t+1} + c^2R_{t+2} + \dots$$

- Giá trị của trạng thái s là

$$V(s) = E(G_t \mid S_t = s).$$

Ví dụ: Robot trong mạng lưới ô vuông

$S = \{(1,1), (1,2), \ldots, (3,3)\}$

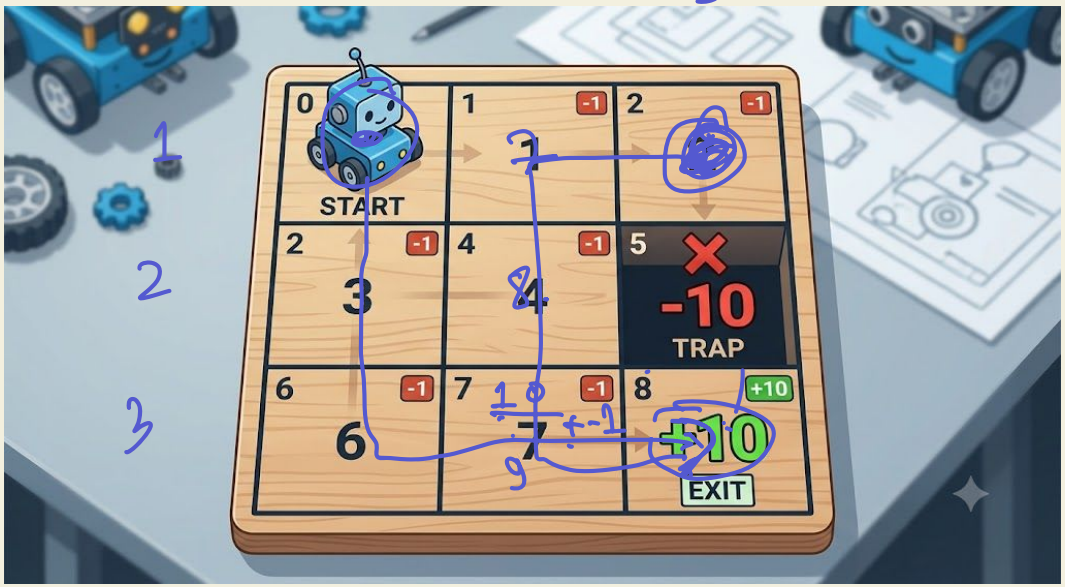
$A = \{\leftarrow, \rightarrow, \uparrow, \downarrow\}$

$R : S \times A \rightarrow \mathbb{R}$

$R((1,1), \rightarrow) = -1$

$R((1,1), \uparrow) = 0$

$R((1,3), \downarrow) = -10$



$\pi : S \rightarrow Prob/A$

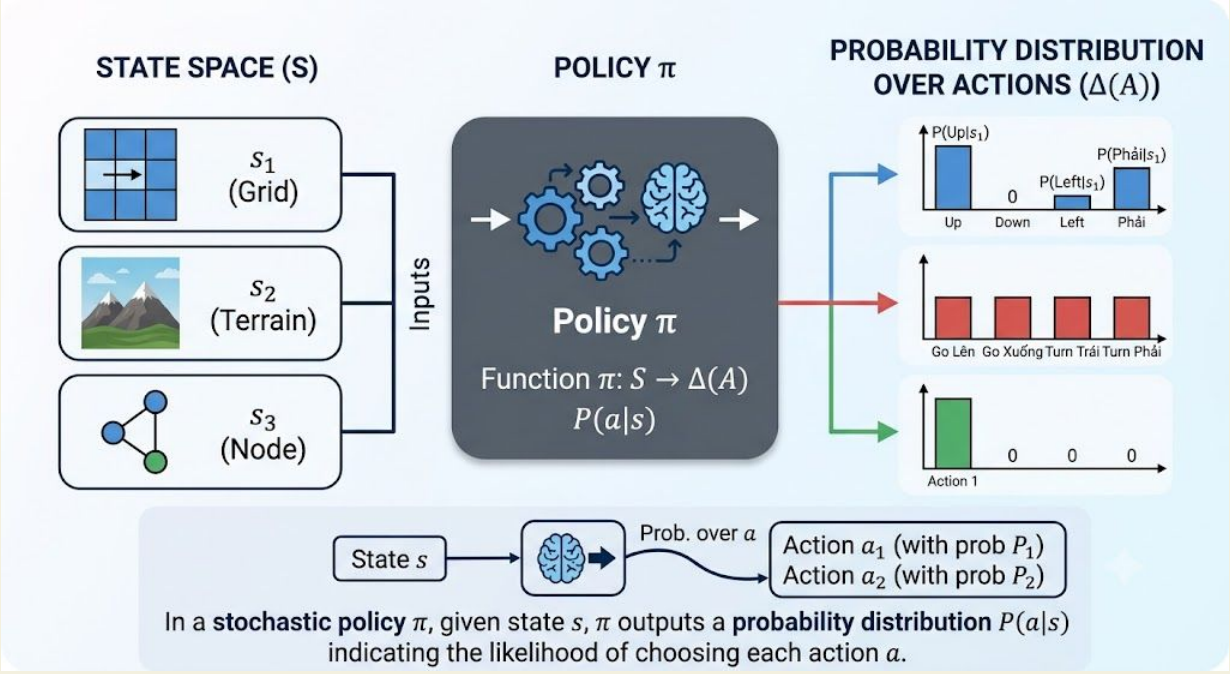
$(1,1) \mapsto (0,0,0,1) = \downarrow$

Chính sách

Định nghĩa. Chính sách là một hàm số π: S -> {Phân bố xác suất trên A}. Chính sách π cho biết xác suất lựa chọn hành động a ở trạng thái s:

$$P_{\pi}(A_t=a \mid S_t=s).$$

π được gọi là tất định nếu phân bố xác suất gồm một hành động duy nhất, khi đó π: S -> A.



Ví dụ: Robot trong mạng lưới ô vuông



Bài toán học tăng cường cho MDP

Định nghĩa. Một quy trình quyết định Markov là một bộ (S, A, P, R, c) với

- S: Tập trạng thái s
- A: Tập hành động a
- P: Xác suất chuyển trạng thái P(s' | s,a)
- R: Phần thưởng R(s,a)
- 0<= c <= 1: Hằng số giảm giá

Bài toán học tăng cường cho MDP.

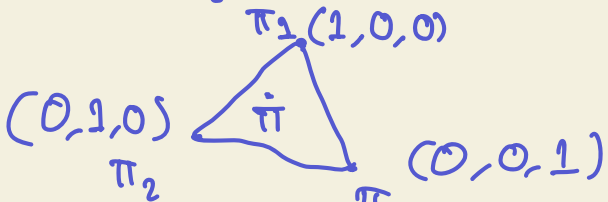
Tìm chính sách π để $V_{\pi}(s)$ đạt giá trị lớn nhất.

Các nội dung hôm nay

1. Tổng quan
2. Quá trình quyết định Markov
3. **Học khi biết về môi trường**
4. Học khi không biết về môi trường

C/M Đ Lý 1. π ngẫu nhiên $\Rightarrow$ $\pi = \sum \alpha_i \pi_i$ với $\sum \alpha_i = 1, \alpha_i \geq 0$

π_i : tất định.



$V_\pi(s)$

$= \alpha_i \sum V_{\pi_i}(s)$

Học khi biết môi trường (model-based)

Bài toán học tăng cường cho MDP.

Tìm chính sách π để $V_\pi(s)$ đạt giá trị lớn nhất.

- Biết môi trường = Cho trước P và R.

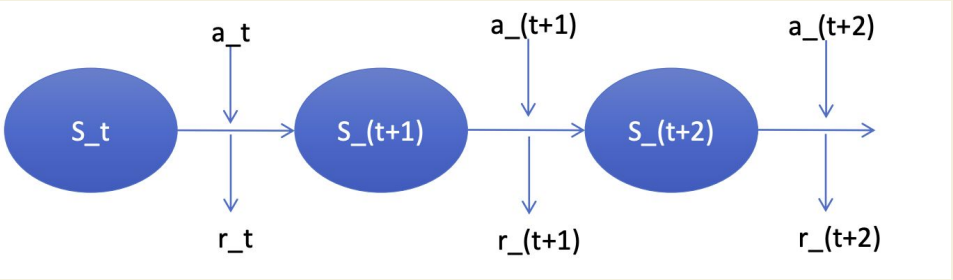
Định lý 1. Với mọi chính sách ngẫu nhiên π, tồn tại chính sách tất định π' có giá trị trạng thái $V_{\pi'}(s) >= V_\pi(s)$.

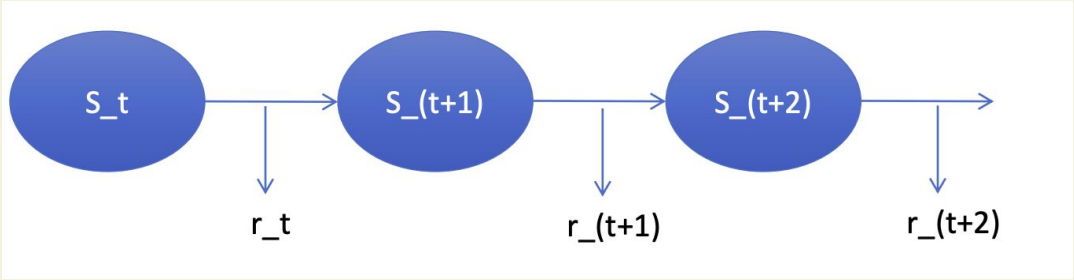
Định lý 2. Tồn tại chính sách π để $V_\pi(s)$ đạt giá trị lớn nhất.

Hệ quả. Chỉ cần tìm chính sách tất định π : S -> A.

- Có thể tìm kiếm (vét cạn) trong không gian $|A|^{|S|}$.
- Tuy nhiên, không hiệu quả => giải pháp: thuật toán lặp.

MDP khi biết chính sách = MRP





- Xác suất chuyển trạng thái

$$P_\pi(S_{t+1}= s' \mid S_t= s) = \sum P(S_{t+1}= s' \mid S_t=s, A_t=a)\, P_\pi(A_t =a \mid S_t=s).$$

- Hàm phần thưởng với chính sách π tại trạng thái s là

$$R_\pi(s) = E(R_t \mid S_t=s) = \sum P_\pi(A_t =a \mid S_t=s)\, R(s,a).$$

→ có tính khi π cố định

- Giá trị với chính sách π tại trạng thái s là

$$V_\pi(s) = E(G_t \mid S_t=s) = R_\pi(s) + c\sum P_\pi(S_{t+1}=s' \mid S_t=s)\, V_\pi(s').$$

Tính giá trị V(s) khi biết chính sách

- Giá trị với chính sách π tại trạng thái s là

$$V_\pi(s) = R_\pi(s) + c\sum P_\pi(S_{t+1}=s' | S_t=s)\, V_\pi(s').$$

Thuật toán 1. Ước lượng $V_\pi(s)$

- Khởi tạo: $V_{\pi,0}(s) = 0$ với mọi s
- Cập nhật đến khi hội tụ: $V_{\pi,k+1}(s) = R_\pi(s) + c\sum P_\pi(S_{t+1}=s' | S_t=s)\, V_{\pi,k}(s')$

Định lý 3. $V_{\pi,k+1}(s)$ tiến đến $V_\pi(s)$ khi k tiến đến vô cùng.

Thuật toán lặp chính sách (Policy iteration)

Thuật toán 2. Lặp chính sách

Khởi tạo: $\pi(0)$ ngẫu nhiên

Cho k=0,1,..., N

- *Đánh giá.* Ước lượng $V_{\pi(k)}(s)$
- *Cập nhật chính sách.* Với mọi s

$$\pi(k+1)(s) = \underset{a \in A}{\operatorname{argmax}}\ R(s,a) + c\sum P(s' \mid s, a)\, V_{\pi(k)}(s')$$

Thuật toán lặp giá trị (Value iteration)

Thuật toán 3. Lặp giá trị

Khởi tạo: V(0) = 0

Cho k=0,1,..., N: Với mọi s

- *Cập nhật giá trị.*

$$V(k)(s) = \max_{a \in A} R(s,a) + c\sum P(s' \mid s, a)\, V(k)(s')$$

- *Cập nhật chính sách.*

$$\pi(k+1)(s) = \operatorname{argmax}_{a \in A} R(s,a) + c\sum P(s' \mid s, a)\, V(k)(s')$$

Các nội dung hôm nay

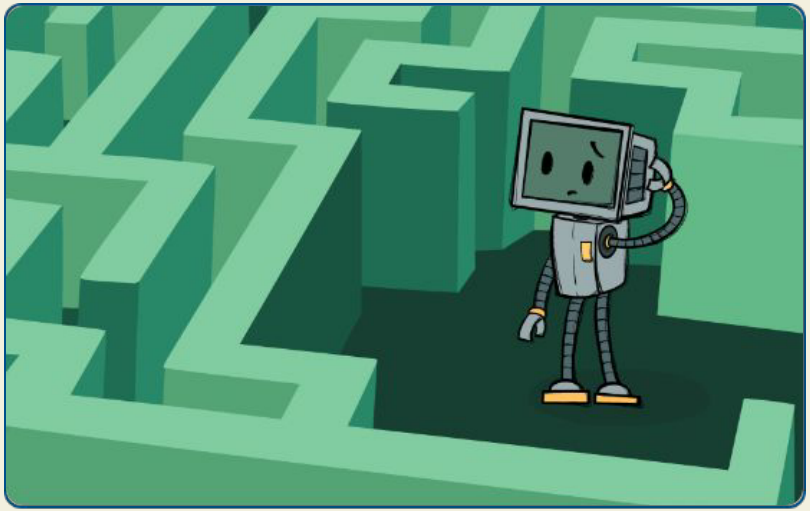
1. Tổng quan
2. Quá trình quyết định Markov
3. Học khi biết về môi trường
4. **Học khi không biết về môi trường**

Học khi không biết môi trường (model-free)

Bài toán học tăng cường cho MDP.

Tìm chính sách π để $V_\pi(s)$ đạt giá trị lớn nhất.

- Không biết môi trường = Không biết trước P và R



Bài toán máy đánh bạc nhiều tay (Multi-armed bandit)

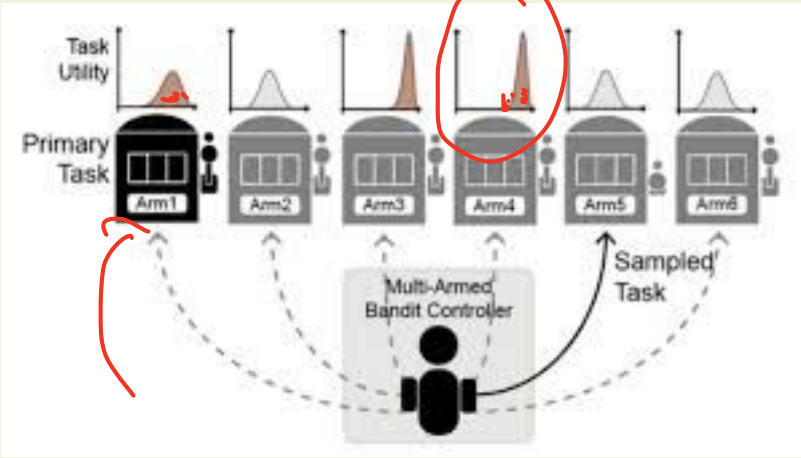
Giả sử mỗi lượt chơi ta có thể chọn chơi 1 trong k máy đánh bạc 1, 2, …, k. Mỗi máy đánh bạc i có phần thưởng là bnn R_i tuân theo phân phối chuẩn chưa biết. Tìm chiến thuật để tối ưu hóa tổng tiền thưởng sau N = 1000 lượt chơi.

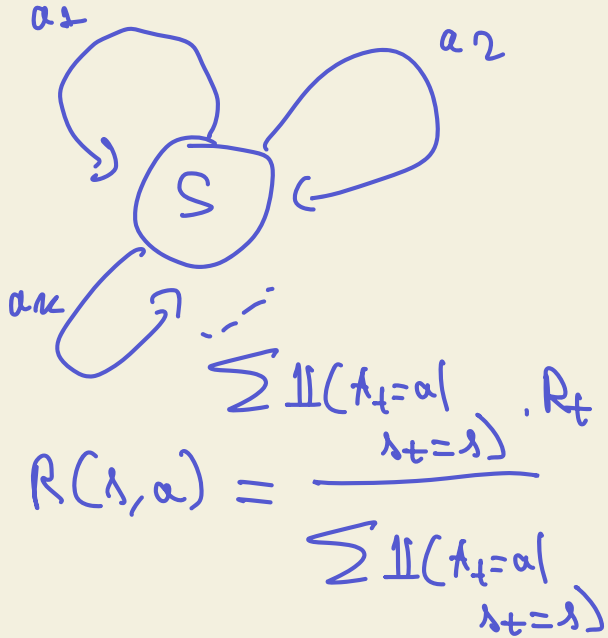
$S = \{s\}$

$A = \{1, \dots, k\}$

A_t : hành động ở thời gian t

R_t : phần thưởng





$$R(s,a) = \frac{\sum \mathbb{1}(A_t = a \mid s_t = s) \cdot R_t}{\sum \mathbb{1}(A_t = a \mid s_t = s)}$$

Đánh đổi khai thác-khám phá

Mỗi lượt chơi chọn lựa giữa

- Khai thác: chọn lại máy có thống kê phần thưởng tốt nhất hiện tại
- Khám phá: chọn máy một cách ngẫu nhiên



Giá trị trung bình Q

Giá trị của trạng thái ở bước thứ t có thể được ước lượng bằng trung bình thực nghiệm (phương pháp Monte-Carlo)

$$Q_t(a) = \frac{\sum_{i=1}^{t-1} \mathbb{1}_i(A_i = a)\, R_i}{\sum_{i=1}^{t-1} \mathbb{1}_i(A_i = a)}$$

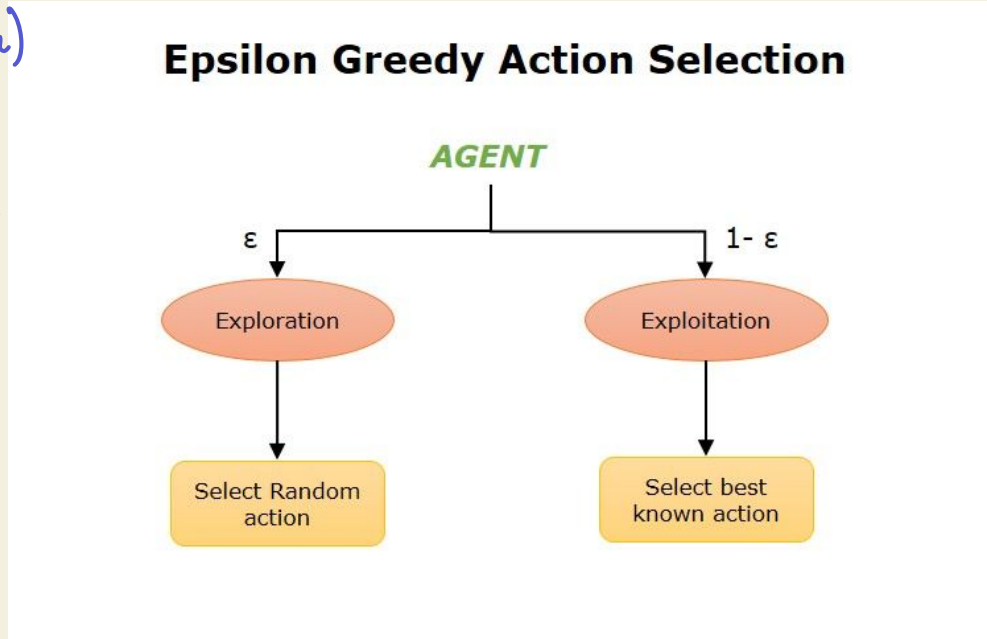
Chiến thuật ε-tham lam

Chọn trước 0<= ε <=1. Mỗi lượt chơi t, chọn

- Khởi tạo $A_1 = 1, \ldots, A_k = k$;
- Với $t > k$: $\forall a$, tính $Q_t(a)$

Chọn $A_t = \arg\max_{a \in A} Q_t(a)$ với xác suất $1-\varepsilon$

Chọn A_t ngẫu nhiên đều từ A với xác suất



Hỏi & Đáp (Q&A)

Cảm ơn các bạn đã lắng nghe!

 ctttrung@fit.hcmus.edu.vn